

FET 445 Veri Madenciliđi

Avustralya Yađmur Tahmini (Rain Prediction in Australia)

Grup : Parlayan Yıldızlar Takımı

YUSUF RIDVAN ÇELİKBAŞ, 22040101055

AYÇA SU YILDIRIM, 22040101049

MUHAMMED EFE KÜÇÜKYETER, 22040101042,

EMRE SOMER ÇABAK, 22040101027,

YouTube Sunum Videosu Bağlantısı

https://youtu.be/_BOL32gbWNM

GitHub/Repo Bağlantısı


github.com/theriay/FET445_TeamShinningStars

Problemın Açıklaması

- **Problem:** Meteorolojik veriler gürültülüdür ve tahmin edilmesi zordur. Yanlış tahminler tarım ve afet yönetimi için risk oluşturur.
- **Temel Zorluk (Class Imbalance):** Veri setimizde ciddi bir sınıf dengesizliği mevcuttur.
 - Yağmur Yok (Class 0): %78 (Çoğunluk)
 - Yağmur Var (Class 1): %22 (Azınlık)
- **Amaç:** Standart modellerin sürekli yağmur yağmayacak diyerek yanıltıcı yüksek doğruluk (accuracy) vermesini engellemek ve SMOTE tekniği ile yağmurlu günleri gerçekten yakalayan bir sistem geliştirmek.

Veri Seti Açıklaması

- **Veri Seti:** Rain in Australia (Kaggle)
- **Link:** [Rain in Australia](#)
- **Boyut:** 145460 Satır, 23 Özellik (Sütun).
- **Hedef Değişken:** RainTomorrow (Yes / No)
- **Sınıf Dağılımı:** Dengesiz (Imbalanced).



Yöntem ve Ön İşleme (Methodology)

Ön İşleme (Feature Engineering):

Tarih Döngüsellliği: Date sütunu Sinüs/Kosinüs dönüşümüyle mevsimsellik bilgisine çevrildi.

Yeni Özellikler: TempDiff (Sıcaklık Farkı), WindHumidIdx (Hissedilen Nem-Rüzgar Endeksi).

Temizlik: Veri kaybını önlemek için eksik veriler silinmedi , dolduruldu.

Eğitim Stratejisi:

Train-Test Split: %80 Eğitim - %20 Test (Stratified K-Fold ile desteklendi).

Dengesizlik Çözümü: Sadece eğitim setine SMOTE uygulandı.

Performans Metrikleri:

F1 Score: Dengesiz veri olduğu için en kritik metrik (Precision ve Recall dengesi).

Recall (Duyarlılık): Yağmuru kaçırmamak için önemli.

ROC-AUC: Modelin ayırt etme gücü.

Accuracy (Doğruluk): Modelin genel başarısı

Precision (Kesinlik): Yanlış Alarm Oranı

En İyi Model (Best Model)

- **Best Model: Random Forest Classifier**
- **Model Geliştirilirken Kullanılan Yaklaşımlar:**
 - Bagging (Bootstrap Aggregating) yöntemi kullanıldı.
 - Boosting modellerinin (XGBoost, CatBoost) aksine, Random Forest birbirine paralel yüzlerce karar ağacı kurarak varyansı düşürdü ve gürültülü veride en kararlı sonucu verdi.
- **Neden Kazandı?**
 - Tablo Sınıf Bazlı Performansa baktığımızda; Extra Trees yağmuru yakalamada (Recall: 0.71) daha iyi olsa da, yanlış alarm oranı yüksekti.
 - Random Forest, Kesinlik (Precision: 0.64) ve Duyarlılık (Recall: 0.67) arasında en mükemmel dengeyi kurarak en yüksek F1 Skoruna (0.656) ulaştı.
- **Hiper-parametreler (RandomizedSearchCV ile Bulunan):**
 - n_estimators: 100
 - max_depth: 20
 - min_samples_split: 5
- **Feature Set (Öne Çıkanlar):** Humidity3pm, Pressure3pm, TempDiff.

Modellerin Karşılaştırılması

- **Neden Class 0 Koymadık ?**
- Çünkü veri setimiz dengesiz (Imbalanced). Yani verinin %78'i zaten Yağmur Yok.
- En dumb model bile (hiçbir şey öğrenmeden) her şeye Yağmur Yok derse, Class 0 başarısı %100 çıkar.
- Bu da tablonun asıl başarısını (Class 1'i) gölgeleyebilir.
- **Tablo Analizi :**
 - Projede; İlk tablo Genel Tablo Analizi . İkinci tablo ise Sınıf Bazlı (Class-1) Yağmur Performansı
 - **Accuracy Tuzağı:** Tabloya dikkatli bakarsak CatBoost %85.3 ile en yüksek Accuracy'ye sahip. Ancak F1 skorunda 4. sırada kalıyor. Çünkü yağmurlu günleri kaçırma oranı yüksek (Recall: 0.54). Bu da dengesiz veride Accuracy'nin neden güvenilirmez olduğunu kanıtlıyor.
 - **Denge:** Lojistik Regresyon yağmuru en çok yakalayan (%77 Recall) model olsa da, çok fazla yanlış alarm veriyor. Random Forest ise bu iki değer in tam ortasında, en güvenilirli yakaladı.

Model	Accuracy	F1 Score	AUC Score
Random Forest	0.841837	0.656064	0.884303
Extra Trees	0.826857	0.648988	0.877982
XGBoost	0.844580	0.634771	0.875026
Gradient Boosting	0.847217	0.633179	0.877194
Stacking Classifier	0.847393	0.632577	0.877578
HistGradientBoosting	0.850839	0.628611	0.882836
CatBoost	0.853827	0.627676	0.884560
Logistic Regression	0.791308	0.625576	
AdaBoost	0.802314	0.621771	0.855557
Naive Bayes	0.755195	0.577087	
k-NN	0.738985	0.547681	
Decision Tree	0.770667	0.53401	
Dummy Classifier	0.499842	0.308575	

Model	Class 1 Precision	Class 1 Recall	Class 1 F1 Score
Random Forest	0.640012	0.672941	0.656064
Extra Trees	0.594799	0.714039	0.648988
XGBoost	0.670683	0.602510	0.634771
Gradient Boosting	0.685558	0.588235	0.633179
Stacking Classifier	0.687144	0.586039	0.632577
HistGradientBoosting	0.711314	0.563137	0.628611
CatBoost	0.731524	0.549647	0.627676
Logistic Regression	0.523217	0.777725	0.625576
AdaBoost	0.544352	0.724863	0.621771
Naive Bayes	0.470903	0.745098	0.577087
k-NN	0.447788	0.704941	0.547681
Decision Tree	0.490356	0.586196	0.534010
Dummy Classifier	0.223568	0.497882	0.308575

Sonuç ve Değerlendirme

- **Sonuç:**

- Toplamda 12 farklı algoritma (Base + Advanced + Ensemble) test edilmiştir.
- Beklentinin aksine, çok karmaşık modeller (Stacking veya XGBoost) yerine, veri setimizin yapısına en uygun olan Random Forest en başarılı model olmuştur.

- **Değerlendirme :**

- Bazen daha basit ve sağlam algoritmalar, aşırı karmaşık sistemlerden daha iyi sonuç verebilir.
- Geliştirdiğimiz Random Forest modeli, Yağmur Yağacak dediğinde %64 ihtimalle haklı çıkarken, yağacak yağmurların %67'sini önceden haber verebilmektedir. Bu, tarımsal planlama için kullanılabilir bir orandır.
- %85 doğruluk oranına sahip modellerin, yağmuru yakalamada başarısız olabileceği kanıtlanmıştır. Projemiz, dengesiz veri setlerinde F1 Skorunun tek geçerli başarı kriteri olduğunu deneysel olarak doğrulamıştır.