



Veri Madenciliği (FET445) – 7. Dönem

(Final Projesi)

Avustralya Meteoroloji Verileri ile Yağmur Tahmini (Sınıflandırma) Parlayan Yıldızlar Takımı

YUSUF RIDVAN ÇELİKBAŞ, 22040101055, yusufridvancelikbas@stu.topkapi.edu.tr
AYÇA SU YILDIRIM, 22040101049, aycasuyildirim@stu.topkapi.edu.tr
MUHAMMED EFE KÜÇÜKYETER, 22040101042, efekucukyeter@stu.topkapi.edu.tr
EMRE SOMER ÇABAK, 22040101027, emresomercabak@stu.topkapi.edu.tr

GitHub/Repo Bağlantısı

github.com/theriay/FET445_TeamShinningStars

İstanbul Topkapı Üniversitesi
Bilgisayar Mühendisliği Bölümü
Proje Özeti

Ocak 2026

1) Giriş

Günümüzde iklim değişikliği ve meteorolojik belirsizlikler; tarım, su kaynakları yönetimi ve afet önleme stratejileri üzerinde kritik bir rol oynamaktadır. Özellikle Avustralya gibi geniş yüzölçümüne ve değişken iklim koşullarına sahip bir bölgede, bir sonraki günün yağış durumunu doğru tahmin edebilmek, ekonomik kayıpların önüne geçilmesi ve operasyonel planlamaların verimliliği açısından hayati önem taşır.

Bu projenin temel motivasyonu, meteorolojik verilerin doğasında bulunan gürültülü (noisy) yapıyı ve veri setindeki sınıflar arası dengesizliği (class imbalance) aşabilecek dayanıklı bir makine öğrenmesi sistemi kurmaktır. Veri setimizde "Yağmur Yok" sınıfının %78, "Yağmur Var" sınıfının ise %22 oranında olması, standart modellerin çoğunluk sınıfına eğilim göstermesine ve kritik olan "yağmur" tahminlerinde başarısız olmasına neden olmaktadır. Bu çalışmada, SMOTE tekniği ve çeşitli gelişmiş topluluk (ensemble) öğrenme algoritmaları kullanılarak, sadece yüksek doğruluk değil, aynı zamanda yüksek yakalama (recall) oranına sahip modellerin geliştirilmesi hedeflenmiştir.

2) Problem Tanımı

İş Sorusu: Geçmiş meteorolojik veriler (nem, basınç, rüzgar hızı vb.) kullanılarak, Avustralya'daki belirli lokasyonlarda bir sonraki gün yağmur yağıp yapmayacağı (*RainTomorrow*) tahmin edilebilir mi?

Görev Türü: İkili Sınıflandırma (Binary Classification).

Hedef Değişken: RainTomorrow (0: Yağış Yok, 1: Yağış Var).

Başarı Kriterleri: Veri setindeki dengesizlik (%78 Hayır, %22 Evet) nedeniyle, doğruluktan ziyade **ROC-AUC ≥ 0.85** ve **F1-Score ≥ 0.60** hedeflenmektedir.

3) Proje Yönetimi

Zaman Çizelgesi:

- **1-2. Hafta:** Veri seti seçimi (Kaggle WeatherAUS) ve literatür taraması.
- **3-8. Hafta:** Veri temizleme, EDA, RISK_MM sızıntı analizi ve eksik veri imputasyonu.
- **9-12. Hafta:** Baseline modellerin (Logistic Regression) kurulması ve Random Forest/XGBoost geliştirmeleri.
- **13-15. Hafta:** Hiper-parametre optimizasyonu (GridSearch), Feature Importance analizi ve Final Raporlama.

Roller:

Yusuf Rıdvan ÇELİKBAŞ:

- Derin Öğrenme ve Boosting Stratejileri: PyTorch kütüphanesi ile "Batch Normalization" içeren özgün bir ANN mimarisi tasarlamış, XGBoost ve CatBoost modellerinin hiperparametre optimizasyonunu yürütmüştür.
- Veri Ön İşleme: Meteorolojik verilerin temizlenmesi ve model eğitime hazır hale getirilmesi süreçlerini yönetmiştir.

Ayça Su YILDIRIM:

- Ağaç Tabanlı Topluluk Modelleri: Projenin en başarılı modeli olan Random Forest Classifier ve Extra Trees modellerini geliştirerek en yüksek F1 skoruna ulaşılmasını sağlamıştır.
- Sınıf Dengesizliği (Imbalance) Yönetimi: SMOTE tekniğinin uygulanması ve modelin "RainTomorrow" azınlık sınıfı üzerindeki performansının artırılmasına odaklanmıştır.

Muhammed Efe KÜÇÜKYETER:

- Gelişmiş Gradient Boosting Modelleri: Scikit-learn tabanlı Gradient Boosting ve HistGradientBoosting modellerini kurarak, bu modellerin eğitim hızı ve doğruluk dengesini analiz etmiştir.
- Derin Öğrenme ve Karar Yapıları: LeakyReLU aktivasyon fonksiyonlu sinir ağları tasarlamış ve temel karar ağaçlarının (Decision Trees) karmaşık modellere göre performansını karşılaştırmıştır.

Emre Somer ÇABAK:

- Ensemble Tasarımı ve Stacking: Birden fazla modelin tahminlerini birleştiren "Stacking Classifier" yapısını kurmuş ve AdaBoost modelini optimize etmiştir.
- Mimari Yenilik ve Analiz: PyTorch üzerinde artık bağlantılı (ResNet) yapılar kullanarak karmaşık mimariler denemiş, modellerin ROC-AUC ve F1 skoru bazı performans analizlerini raporlamıştır.

4) İlgili Çalışmalar (Literatür İncelemesi)

Literatürdeki (I. A. Obaidalla, S. L. Ezamzuri et al.) çalışmalar genellikle Accuracy metriğine odaklanmış ve eksik verileri silme yoluna gitmiştir.

Projemizin Literatürden Farkları (Gap Analysis):

- **Sistematiik Karşılaştırma:** Tek bir model ailesi yerine 4 farklı aile (Lineer, Ağaç, Boosting, Uzaklık) A/B testi mantığıyla kıyaslanmaktadır.


- **Veri Yönetimi:** Veri kaybını önlemek için satır silmek yerine Medyan/Mod imputasyonu ve Tarih Mühendisliği uygulanmıştır.
- **Metrik Seçimi:** "Accuracy Tuzağı"ndan kaçınılarak, dengesiz veri setleri için daha güvenilir olan F1-Score ve ROC-AUC metrikleri esas alınmıştır.

5) Veri Tanımı ve Yönetimi

- **Veri Seti:** Avustralya Meteoroloji Bürosu verileri (WeatherAUS).
- **Boyut:** 145.460 satır, 23 sütun.
- **Veri Şeması:** Sayısal (MinTemp, MaxTemp, Rainfall, Pressure) ve Kategorik (Location, WindDir) değişkenler.
- **Gizlilik:** Veriler halka açık anonim meteorolojik kayıtlardır; kişisel veri (PII) içermez.


6) Keşifsel Veri Analizi (EDA)

- **Eksik Veriler:** Evaporation (%43) ve Sunshine (%48) sütunlarında yüksek eksiklik tespit edilmiş ve istatistiksel yöntemlerle doldurulmuştur.
- **Sınıf Dengesi:** Veri seti dengesizdir (Negatif sınıf baskın).
- **Aykırı Değerler:** Rainfall değişkenindeki aşırı değerler, meteorolojik gerçeklik (fırtına vb.) olduğu için korunmuştur.
- **Korelasyon:** Temp9am ile Temp3pm (0.86) arasında güçlü korelasyon görülmüş, bu da Çoklu Doğrusal Bağlantı (Multicollinearity) riskine karşı PCA kullanımını desteklemiştir.




Şekil 1: Özellikler Arası Korelasyon Matrisi


- **Belirleyici Özellik:** Humidity3pm (Saat 15:00 Nemi), yağış tahmininde en ayırt edici özellik olarak tespit edilmiştir.



Şekil 2: Hedef Değişkenin Dengesiz Dağılımı



Şekil 3: Yağmur Durumuna Göre Nem Oranı Dağılımı



Şekil 4: Aylara Göre Yağışlı Gün Sayısı

7) Veri Hazırlama Planı

Final modellemede kullanılan veri işleme adımları ("untitled38" mantığına göre):

1. **Temizleme:** Hedef değişkeni doğrudan içeren RISK_MM sütunu çıkarıldı.
2. **İmputasyon:** Sayısal veriler **Medyan**, kategorik veriler **Mod** ile dolduruldu.
3. **Kodlama:** Location ve rüzgar yönleri için **Label Encoding**, hedef değişken için **Binary Encoding** yapıldı.
4. **Ölçeklendirme:** Lojistik Regresyon performansı için **StandardScaler** uygulandı.
5. **Özellik Seçimi:** PCA ve XGBoost Feature Importance ile en etkili değişkenler belirlendi.

8) Modelleme Planı

Dört temel model ailesi kullanılmış ve `class_weight='balanced'` parametresi ile dengesizlik yönetilmiştir:

Sorumlu Üye	Model	Seçilme Nedeni ve Odak Noktası
Rıdvan	Logistic Regression	Yorumlanabilirlik: Değişkenlerin etkisini katsayılarla açıklama ve temel başarımlar (baseline) ölçümü.
Ayça	Random Forest	Kararlılık: Çoklu ağaç yapısıyla varyansı düşürme ve gürültülü veriye karşı direnç sağlama.
Efe	Decision Tree	Görsel Analiz: Karar mekanizmasını "IfThen" kuralları ve ağaç grafiğiyle şeffaf hale getirme.
Somer	XGBoost & Bagging	Performans: Ardışık öğrenme (Boosting) ile hatayı minimize etme ve en yüksek skoru hedefleme.

Model Mimarileri ve Eğitim Stratejisi

Proje kapsamında sadece klasik algoritmalarla yetinilmemiş, her ekip üyesi farklı bir derin öğrenme (Deep Learning) mimarisi ve optimizasyon stratejisi üzerinde uzmanlaşmıştır:

- Derin Sinir Ağları (ANN):** Modelin genelleme yeteneğini artırmak için PyTorch kütüphanesi kullanılarak; Batch Normalization (Yusuf Rıdvan), Dropout katmanları (Ayça Su), LeakyReLU aktivasyon fonksiyonları (Muhammed Efe) ve ResNet benzeri artık bağlantılı (skip-connections) yapılar (Emre Somer) içeren özgün mimariler tasarlanmıştır.
- Ensemble ve Stacking:** Karmaşık veri yapılarını modellemek amacıyla, Random Forest ve XGBoost gibi güçlü modellerin tahminlerini birleştiren bir Meta-Learner (Lojistik Regresyon) üzerinden "Stacking Classifier" yapısı kurulmuştur.

9) Değerlendirme Tasarımı

Model	Accuracy	F1-Score (Weighted)	AUC Score	Recall (Yağmur Sınıfı)
Random Forest	0.846	0.846	0.887	0.668
Stacking Classifier	0.844	0.845	0.887	0.677
Extra Trees	0.845	0.845	0.887	0.653
XGBoost	0.843	0.841	0.876	0.624
Gradient Boosting	0.851	0.845	0.883	0.580
Logistic Regression (Base)	0.846	0.835	0.870	0.501

Tablo 1: Final Modellerin Performans Karşılaştırması (Test Verisi)

Genel Değerlendirme:

Tablo 1'de görüldüğü üzere, **Random Forest** modeli hem **ROC-AUC (0.887)** hem de **F1-Score (0.846)** metriklerinde en dengeli ve yüksek performansı sergilemiştir. Base model (Logistic Regression) ile kıyaslandığında, final modellerimiz özellikle "Yağmur Var" sınıfını yakalama (Recall) konusunda önemli bir iyileştirme sağlamıştır.

Modelin başarısını detaylandırmak için "Sınıf Bazlı Performans" (Class-wise Breakdown) sonuçları incelenmiştir:


Model	Sınıf	Precision	Recall	F1-Score
Random Forest	0 (No Rain)	0.9034	0.8971	0.9003
	1 (Rain)	0.6523	0.6681	0.6601
XGBoost	0 (No Rain)	0.8930	0.9060	0.8995
	1 (Rain)	0.6575	0.6243	0.6405
CatBoost	0 (No Rain)	0.8994	0.8789	0.8890
	1 (Rain)	0.6115	0.6596	0.6346

Model	Sınıf	Precision	Recall	F1-Score
Gradient Boosting	0 (No Rain)	0.8845	0.9288	0.9061
	1 (Rain)	0.7018	0.5801	0.6352
Extra Trees	0 (No Rain)	0.8998	0.9008	0.9003
	1 (Rain)	0.6554	0.6527	0.6540
AdaBoost	0 (No Rain)	0.9105	0.8120	0.8585
	1 (Rain)	0.5267	0.7238	0.6097
HistGradientBoosting	0 (No Rain)	0.8939	0.9016	0.8977
	1 (Rain)	0.6489	0.6298	0.6392
Stacking Classifier	0 (No Rain)	0.9052	0.8919	0.8985
	1 (Rain)	0.6439	0.6769	0.6600

Tablo 2: Hedef Sınıf (Yağmur Var/Yok) Bazlı Kırılım

Sınıf Başarısı Yorumu:

- Veri setindeki dengesizliğe rağmen, **Random Forest** modeli "Yağmur Var" (Sınıf 1) durumunu %66.8 oranında (Recall) doğru tespit etmiştir.
- AdaBoost** modeli %72.4 ile yağmuru en çok yakalayan model olsa da, yanlış alarm oranı (düşük Precision: 0.52) yüksek olduğu için genel başarıda (F1) Random Forest'in gerisinde kalmıştır.
- Sonuç olarak; yanlış alarmları minimize eden ve yağmuru yakalama dengesini en iyi kuran **Random Forest** final modeli olarak seçilmiştir.



Şekil5: Pilot Modelin (Logistic Regression) Karışıklık Matrisi. Modelin çoğunluk sınıfını (Sol Üst) iyi bildiği, ancak azınlık sınıfında (Sağ Alt) iyileştirmeye ihtiyaç duyduğu görülmektedir.

Model	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score (Denge)
Random Forest	0.6523	0.6681	0.6601
Stacking Classifier	0.6439	0.6769	0.6600
Extra Trees	0.6554	0.6527	0.6540
XGBoost	0.6575	0.6243	0.6405
HistGradientBoosting	0.6489	0.6298	0.6392
Gradient Boosting	0.7018	0.5801	0.6352
CatBoost	0.6115	0.6596	0.6346
AdaBoost	0.5267	0.7238	0.6097

Tabloya göre Random Forest ve Stacking Classifier, hem yağmuru yakalama hem de yanlış alarmları en aza indirme konusundaki dengeli başarılarıyla (0.66 F1-Skoru) projenin en iyi modelleri olmuştur. AdaBoost modeli yağmurlu günlerin çoğunu (%72 Recall) tespit etse de, çok fazla yanlış alarm verdiği için genel başarıda geride kalmıştır. Buna karşılık Gradient Boosting, yaptığı tahminlerde en yüksek kesinliği (%70 Precision) sağlasa da, çok temkinli davrandığı için birçok yağmurlu günü tahmin edememiştir.

Model	Accuracy	Balanced Accuracy	Precision (Weighted)	Recall (Weighted)	F1 Score (Weighted)	AUC Score
[Base] Dummy Classifier	0.6511	0.4974	0.6504	0.6511	0.6507	0.4974
[Base] Logistic Regression	0.8461	0.7235	0.8363	0.8461	0.8352	0.8698
[Base] Naive Bayes	0.7606	0.7340	0.8019	0.7606	0.7741	0.8163
[Base] k-NN	0.8104	0.6586	0.7918	0.8104	0.7926	0.7704
[Base] Decision Tree	0.7874	0.6996	0.7897	0.7874	0.7885	0.6996
[Final] Random Forest	0.8458	0.7826	0.8471	0.8458	0.8464	0.8870
[Final] XGBoost	0.8429	0.7652	0.8402	0.8429	0.8414	0.8765
[Final] CatBoost	0.8297	0.7693	0.8348	0.8297	0.8320	0.8679
[Final] Gradient Boosting	0.8506	0.7544	0.8435	0.8506	0.8454	0.8831
[Final] Extra Trees	0.8452	0.7767	0.8450	0.8452	0.8451	0.8867
[Final] AdaBoost	0.7923	0.7679	0.8245	0.7923	0.8027	0.8550
[Final] HistGradientBoosting	0.8406	0.7657	0.8390	0.8406	0.8398	0.8749
[Final] Stacking Classifier	0.8437	0.7844	0.8467	0.8437	0.8450	0.8866

Tablo Yorumu

Final modelleri (özellikle Random Forest ve Stacking Classifier), temel (Base) modellere kıyasla hem ayırt edicilik (AUC) hem de denge (F1-Score) açısından belirgin bir performans artışı göstermiştir. **Random Forest**, **0.8870 AUC** ve **0.8464 F1 skoru** ile modelin genelleme yeteneği en yüksek algoritma olarak öne çıkarken; **Gradient Boosting 0.8506** ile en yüksek doğruluğa (Accuracy) ulaşmıştır. Ancak dengesiz veri setlerinde kritik olan "Balanced Accuracy" metriğinde **Stacking Classifier (0.7844)** ve Random Forest liderliği paylaşarak, azınlık sınıfı tahmin etmede en güvenilir modeller olduklarını kanıtlamışlardır.

Model	Sınıf (Class)	Precision	Recall	F1-Score
[Base] Dummy Classifier	0 (No Rain)	0.7747	0.7760	0.7753
	1 (Rain)	0.2201	0.2188	0.2195
[Base] Logistic Regression	0 (No Rain)	0.8678	0.9457	0.9051
	1 (Rain)	0.7274	0.5013	0.5936
[Base] Naive Bayes	0 (No Rain)	0.8960	0.7823	0.8353
	1 (Rain)	0.4765	0.6856	0.5622
[Base] k-NN	0 (No Rain)	0.8398	0.9337	0.8843
	1 (Rain)	0.6256	0.3835	0.4755
[Base] Decision Tree	0 (No Rain)	0.8661	0.8588	0.8624
	1 (Rain)	0.5252	0.5404	0.5327
[Final] Random Forest	0 (No Rain)	0.9034	0.8971	0.9003
	1 (Rain)	0.6523	0.6681	0.6601
[Final] XGBoost	0 (No Rain)	0.8930	0.9060	0.8995
	1 (Rain)	0.6575	0.6243	0.6405
[Final] CatBoost	0 (No Rain)	0.8994	0.8789	0.8890
	1 (Rain)	0.6115	0.6596	0.6346
[Final] Gradient Boosting	0 (No Rain)	0.8845	0.9288	0.9061

Model	Sınıf (Class)	Precision	Recall	F1-Score
	1 (Rain)	0.7018	0.5801	0.6352
[Final] Extra Trees	0 (No Rain)	0.8998	0.9008	0.9003
	1 (Rain)	0.6553	0.6527	0.6540
[Final] AdaBoost	0 (No Rain)	0.9105	0.8120	0.8585
	1 (Rain)	0.5267	0.7238	0.6097
[Final] HistGradientBoosting	0 (No Rain)	0.8939	0.9016	0.8977
	1 (Rain)	0.6489	0.6298	0.6392
[Final] Stacking Classifier	0 (No Rain)	0.9052	0.8919	0.8985
	1 (Rain)	0.6439	0.6769	0.6600

Tablo Yorumu

Random Forest ve Stacking Classifier, yağmurlu günleri tespit etme (Recall) ve yanlış alarmları önleme (Precision) arasındaki en iyi dengeyi kurarak 0.66 F1-Score ile en başarılı modeller olmuştur. AdaBoost modeli, %72.4 gibi yüksek bir Recall oranıyla yağmurlu günleri en çok yakalayan model olsa da, düşük kesinlik oranı (%52.7) nedeniyle çok fazla yanlış alarm vermektedir. Buna karşılık Gradient Boosting, %70.2 ile en yüksek kesinliği (Precision) sunmasına rağmen, temkinli yapısı nedeniyle yağışlı günlerin yalnızca %58'ini tespit edebilmiştir.

10) Riskler ve Azaltma Yöntemleri

- **Accuracy Paradox:** Modelin sürekli "Yağmur Yok" diyerek %78 doğruluk alması riski.
 - *Çözüm:* F1-Score ve ROC-AUC metrikleri ana başarı kriteri olarak belirlendi.
- **Overfitting (Aşırı Öğrenme):** Ağaç tabanlı modellerin veriyi ezberlemesi.
 - *Çözüm:* max_depth sınırlandırması ve Cross-Validation (Çapraz Doğrulama) uygulandı.


11) Kullanılan Araçlar

- **Kod Dosyası:** weatherAusCodes.ipynb


- **Kütüphaneler:** Pandas, Scikit-learn, XGBoost, Seaborn/Matplotlib.
- **Donanım:** Python 3.9+, Jupyter Notebook, Anaconda.

12) Beklenen Sonuçlar ve Görselleştirme Planı

Vize aşamasında kullanılan temel modellerde Recall (Yağmuru Yakalama) oranı **0.50** seviyelerindeyken, final projesinde uyguladığımız **SMOTE** (sentetik veri üretimi) ve **Hiperparametre Optimizasyonu** teknikleri sayesinde bu oran **Stacking ve Random Forest** modellerinde **0.67** seviyelerine çıkarılmıştır. Projemiz **0.887** AUC skoru ile hedeflenen başarı kriterlerini ($AUC > 0.85$) fazlasıyla karşılamıştır.





Şekil 6: Random Forest Modeli için Karışıklık Matrisi



Random Forest ve XGBoost modellerine göre yağmuru tahmin etmede en etkili ilk 5 faktör:

Sıra	Özellik (Feature)	Açıklama	Önem Skoru (Yaklaşık)
1	Humidity3pm	Saat 15:00'teki Nem Oranı	0.168
2	Pressure3pm	Saat 15:00'teki Atmosfer Basıncı	0.062
3	Sunshine	Günlük Güneşlenme Süresi	0.061
4	WindGustSpeed	En Yüksek Rüzgar Hızı	0.057
5	Pressure9am	Saat 09:00'daki Atmosfer Basıncı	0.054

Tablo 2: Özellik Önem Düzeyleri (Feature Importance)



Sonuç

Modelimiz, fiziksel gerçeklikle örtüşen bir şekilde **Nem** ve **Basınc** verilerini en önemli indikatörler olarak belirlemiştir. Bu durum, modelin sadece veriyi ezberlemediğini, meteorolojik ilişkileri de öğrendiğini kanıtlamaktadır.

Performans Değerlendirmesi ve "Accuracy" Paradoksu

Sınıf dengesizliği olan veri setlerinde "Accuracy" (Doğruluk) metriğinin ne kadar yanıltıcı olabileceği projemizde deneysel olarak kanıtlanmıştır. Örneğin; CatBoost modeli %85.3 ile en yüksek doğruluk oranına ulaşmasına rağmen, yağmurlu günleri yakalama (Recall) başarısı %54.9'da kalarak F1 skorunda 4. sıraya gerilemiştir. Buna karşılık Random Forest modeli, %64 hassasiyet (Precision) ve %67 duyarlılık (Recall) dengesiyle 0.656 F1 skoruna ulaşarak projenin en güvenilir modeli seçilmiştir. Bu durum, modelin sadece "yağmur yok" dediğinde haklı çıkmasını değil, "yağmur yağacak" dediğinde de yüksek bir isabet oranına sahip olmasını sağlamıştır.

Teşekkür

Bu projenin hazırlık ve geliştirme sürecinde, veri madenciliği konusundaki engin tecrübelerini bizlerle paylaşan, ders boyunca sağladığı teorik altyapı ve pratik yönlendirmelerle ufukumuzu açan değerli hocamız **YILDIZ KARADAYI**'na; akademik destekleri ve motive edici yaklaşımı için en içten teşekkürlerimizi sunarız. Ayrıca, projenin her aşamasında büyük bir özveriyle çalışan, bilgi paylaşımını ve ekip ruhunu ön planda tutan tüm grup arkadaşlarımıza teşekkür ederiz.

Referanslar

1. I. A. Obaidalla, "Rainfall prediction using machine learning methods," RIT Dubai, 2024.
2. S. L. Ezamzuri et al., "Comparative analysis of ML algorithms for rainfall prediction," ICAROB, 2025.
3. Commonwealth of Australia, Bureau of Meteorology (2024). Climate Data Online.